ARAÇ HASAR TESPİTİ (CAR DAMAGE) PROJESİ

Yeni Nesil Nesne Tespiti ve Segmentasyon Modelleri Karşılaştırma Raporu

1. Çalışmanın Amacı ve Kapsamı

Bu çalışmada, araç üzerindeki hasarların (çatlak, göçük vb.) tespiti için iki farklı modern derin öğrenme mimarisi karşılaştırılmıştır:

- **Model A:** Transformer tabanlı **RF-DETR (Base)** modeli (Sadece Nesne Tespiti - Bounding Box).
- **Model B:** CNN tabanlı ve YOLO'nun en gelişmiş varyasyonlarından biri olan **YOLO11l-seg** modeli (Nesne Tespiti + Piksel Bazlı Segmentasyon).

Modeller, aynı veri seti üzerinde Google Colab ortamında (NVIDIA A100 GPU) eğitime alınmış ve performansları mAP (Mean Average Precision), eğitim süreleri ve stabilite açısından kıyaslanmıştır.

> ***Not:*** *Projenin orijinal hedef modellerinden biri olan **RT-DETR** mimarisi, tıpkı RF-DETR gibi varsayılan olarak piksel bazlı segmentasyon (maskeleme) yeteneğine sahip değildir. Araç hasarları asimetrik olduğu için sadece bounding box (kutu) tespiti yeterli görülmemiş ve bu sebeple RT-DETR modeli değerlendirme kapsamı dışında bırakılmıştır.*

2. Modellerin Eğitim Süreçleri ve Gözlemler

RF-DETR (Base) Eğitim Süreci:

- Model, batch işlemlerinde `840/1024`px gibi yüksek çözünürlüklerle eğitime başlamıştır.
- Transformer mimarisinin doğası gereği oldukça yavaş öğrenme eğilimi göstermiş ve 31. epoch'a ulaşıldığında mAP50-95 skoru ancak **%65.7** (0.6571) seviyesine tırmanabilmiştir.
- **Erken Sonlandırma:** Modelin yavaş yakınsama (convergence) eğilimi ve donanım kısıtlamaları göz önüne alınarak, eğitim süreci 31. epoch'ta manuel olarak durdurulmuş ve erken aşama metrikleri analize dahil edilmiştir.

YOLO11l-seg Eğitim Süreci:

- YOLO modeli, maskeleme (segmentasyon) görevini de üstlenmesine rağmen 100 epoch'luk eğitimi stabil bir şekilde 4.15 saatte tamamlamıştır.
- Eğitim boyunca hem `box_loss` hem de `seg_loss` kusursuz bir grafikle düşüş göstermiştir.

- Model, finalde araç hasarlarını sadece kutu içine almakla kalmamış, hasarın şeklini piksel bazında **%91.2** (Mask mAP50) doğrulukla çizebilecek seviyeye gelmiştir.

3. Performans ve Metrik Karşılaştırması

Aşağıdaki tablo, modellerin ulaştıkları en iyi metrikleri kıyaslamaktadır:

Karşılaştırma Kriteri	RF-DETR (Base)	YOLO11l-seg	Kazanan
Mimari Yapısı	Transformer (LWDETR)	CNN (Kapsamlı C3k2/ SPPF)	-
Görev Tipi	Nesne Tespiti (Bbox)	Nesne Tespiti + Segmentasyon	**YOLO11l-seg**
Model Parametresi	31.9 Milyon	27.6 Milyon	**YOLO11l-seg (Daha Hafif)**
Tamamlanan Epoch	**31 / 100 (Manuel Durduruldu)**	100 / 100 (Tamamlandı)	**YOLO11l-seg**
Bbox mAP@50 Skoru	~ %88.0 (Erken Aşama)	**%91.3**	**YOLO11l-seg**
Bbox mAP@50-95	%65.7	**%79.6**	**YOLO11l-seg**
Mask mAP@50	Desteklemiyor	**%91.2**	**YOLO11l-seg**

4. Sonuç ve Teknik Değerlendirme

Yapılan testler sonucunda **YOLO11l-seg** modelinin "Araç Hasar Tespiti" probleminde erken sonuçlara göre üstünlük sağladığı görülmüştür. Bu durumun başlıca mühendislik sebepleri şunlardır:

- **Segmentasyon İhtiyacı ve RT-DETR'ın Elenmesi:** Araç hasarları (çizik, çatlak vb.) asimetrik yapılar olduğu için sadece "kutu (bounding box)" çizen modeller problemi çözmekte yetersiz kalmaktadır. Proje başlarında değerlendirilmesi planlanan **RT-DETR** modelinin de (tıpkı RF-DETR gibi) doğal bir segmentasyon özelliği sunmaması, bu tarz spesifik hasar tespit görevlerinde

değerlendirme dışı bırakılmasına sebep olmuştur. YOLO modeli ise segmentasyon görevini başarıyla üstlenerek problemi daha efektif çözmüştür.

- **Eğitim Hızı ve Yakınsama (Convergence):** Transformer tabanlı modeller (RF-DETR), doğaları gereği potansiyellerine ulaşmak için çok uzun eğitim sürelerine (300+ epoch) ihtiyaç duyarlar. Buna karşılık CNN tabanlı YOLO modeli çok daha hızlı yakınsamış ve 100 epoch içinde problemi çözmüştür. Bu nedenle RF-DETR eğitimi 31. epoch'ta yeterli veri sağladığı düşünülerek sonlandırılmıştır.